



# Sistemas de inteligencia artificial

## TP3: Perceptron simple y multicapa


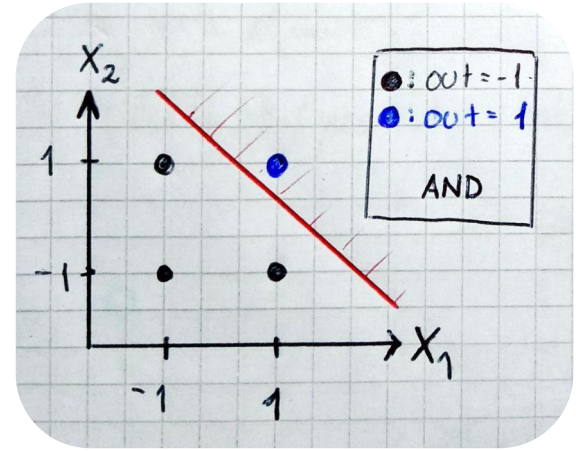
Grupo 19

Integrantes:

- Lucas Catolino
- Matias Ricarte


# Sobre el perceptrón simple escalón

- El perceptrón simple escalón es útil a la hora de resolver problemas de separabilidad lineal.
- XOR **no** es parte de ese conjunto de problemas.




# Perceptrón simple: modelo y algoritmo

```
i = 0
w = zeros(N+1, 1)
error = 1
error_min = p * 2
while error > 0 & i < COTA
    Tomar un número i_x al azar entre 1 y p
    Calcular la excitación  $h = x[i\_x].w$ 
    Calcular la activación  $O = \text{signo}(h)$ 
     $\Delta w = \eta * (y[i\_x] - O).x[i\_x]$ 
     $w = w + \Delta w$ 
    error = CalcularError(x, y, w, p)
    if error < error_min
        error_min = error
        w_min = w
    end
    i = i + 1
end
```



1. Inicializar el conjunto de pesos en valores 'pequeños' al azar.
2. Tomar un ejemplo  $\xi^\mu$  al azar del conjunto de entrenamiento y  
 $V_k^0 = \xi_k^\mu$  para todo  $k$ . aplicarlo a la capa 0:
3. Propagar la entrada hasta a capa de salida  
 $V_i^m = g(h_i^m) = g(\sum_j w_{ij}^m V_j^{m-1})$  para todo  $m$  desde 1 hasta  $M$ .
4. Calcular  $\delta$  para la capa de salida  
 $\delta_i^M = g'(h_i^M)(\zeta_i^\mu - V_i^M)$
5. Retropropagar  $\delta_i^M$  a la capa  $m - 1$   
 $\delta_j^{m-1} = g'(h_j^{m-1}) \sum_i w_{ij}^m \delta_i^m$  para todo  $m$  entre  $M$  y 2
6. Actualizar los pesos de las conexiones de acuerdo  
 $w_{ij}^{nuevo^m} = w_{ij}^{viejo^m} + \Delta w_{ij}^m$   
donde  $\Delta w_{ij}^m = \eta \delta_i^m V_j^{m-1}$
7. Calcular el *error*. Si *error* > COTA, ir a 2.



# Resultados para el primer ejercicio

```
"SolutionInfo": {  
  "iterations": 7,  
  "epochs": 1,  
  "params": {  
    "iterationLimit": 1000,  
    "learningRate": 0.1,  
    "minAcceptable": 0.0,
```

```
"stopReason": "MINACCEPTABLE",  
"bestIteration": {  
  "w": [0.30000000000000004, 0.10000000000000003, -0.30000000000000004],  
  "error": 0.0  
}
```

```
"SolutionInfo": {  
  "iterations": 1000,  
  "epochs": 249,  
  "params": {  
    "iterationLimit": 1000,  
    "learningRate": 0.1,  
    "minAcceptable": 0.0,
```

```
"stopReason": "MAXITER",  
"bestIteration": {  
  "w": [0.1, -0.10000000000000003, -0.09999999999999998],  
  "error": 2.0  
}
```

# Sobre el perceptrón simple lineal y no lineal

Para el ejercicio 2 se nos dio un dataset de entradas y salidas para probar con estos 2 tipos de perceptrones simples.

- En el lineal no fue posible bajar el error a un valor apropiado para decir que la red “aprendió” cómo resolver el problema. Esto nos lleva a pensar que la función a aprender **no** es una transformación lineal.


```
"stopReason": "MAXITER",  
"bestIteration": {  
  "w": [6.421472086866038, 6.601156358231627, 6.84386343000651, 42.85802715722375],  
  "error": 9257.06608157755  
}
```

```
"SolutionInfo": {  
  "iterations": 500000,  
  "epochs": 2499,  
  "params": {  
    "iterationLimit": 500000,  
    "learningRate": 0.001,  
    "minAcceptable": 0.5,  
    "trainingDataInputs": [
```

# (cont.)

```
"elapsedTimeMillis": 34217,  
"stopReason": "MAXITER",  
"bestIteration": {  
  "w": [0.23346248990706792, 0.2662405177410216, -0.21138101169215484],  
  "error": 17.38400292356527  
}
```

Error vs Iterations



```
"SolutionInfo": {  
  "iterations": 2000000,  
  "epochs": 9999,  
  "params": {  
    "iterationLimit": 2000000,  
    "learningRate": 0.01,  
    "minAcceptable": 0.0,  

```

```
"trainingDataInputSize": 200,  
"perceptronMode": "nonlinear",  
"kCuts": 4,  
"beta": 0.8,  
"sigmoidType": "tanh",  
"printHistory": "both"
```



## Aplicando validación cruzada en $k$ partes

```
"iterationLimit": 2000000,  
"learningRate": 0.01,
```

```
"perceptronMode": "nonlinear",  
"sigmoidType": "tanh",  
"beta": 0.8,  
"printHistory": "both",  
"kCuts": 4
```

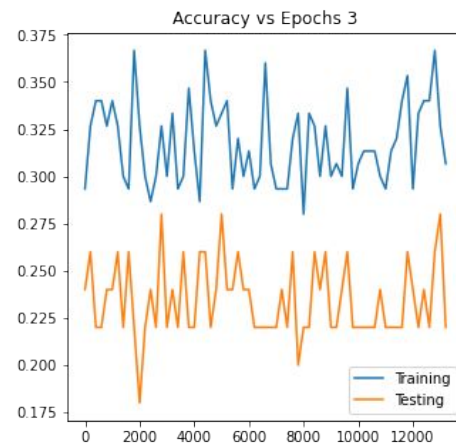



A la hora de evaluar la capacidad de generalización del perceptrón, decidimos seguir utilizando los parámetros con los que menor error encontramos, ya que aunque los pesos que se creasen a partir de los diferentes subconjuntos de entrenamiento serán diferentes, el beta, la función sigmoide y la tasa de aprendizaje siguen siendo parte del perceptron a evaluar.

```
public double ACCURACY_EPSILON = 0.18;
```

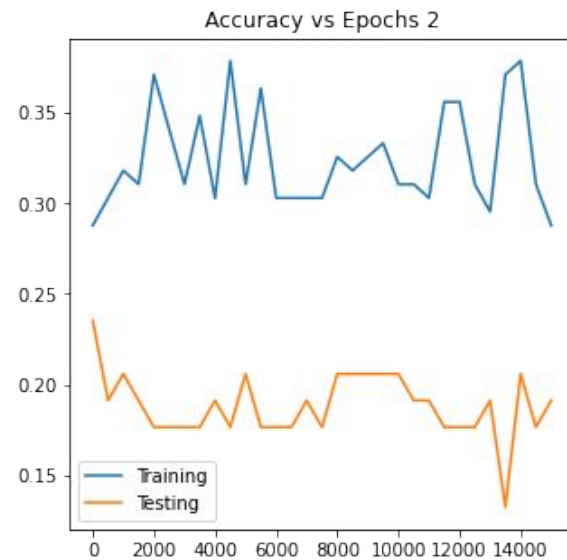


```
double testAcc = calculateAccuracy(w, testingSetInputs, testingSetOutputs, ACCURACY_EPSILON);
```



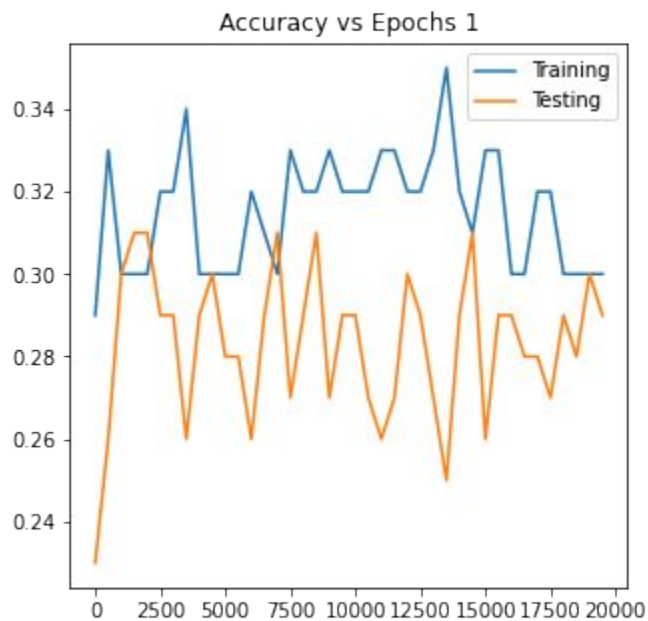

## Con $k = 4$



Con  $k = 3$



Con  $k = 2$





## Sobre el perceptrón multicapa

Para el ejercicio 3 se nos dio un conjunto de datasets de entradas y salidas. La implementación del perceptrón multicapa sigue la siguiente arquitectura:

- El perceptrón es un arreglo de capas
- Cada capa tiene un arreglo de unidades
- Cada unidad calcula y conoce su excitación, activación y pesos sinápticos


## Ejercicios del perceptrón multicapa

Ejercicio 3.1: dada la función XOR calcular la salida

Entrada:  $x = \{-1, 1\}, \{1, -1\}, \{-1, -1\}, \{1, 1\}$

Salida esperada:  $y = \{1, 1, -1, -1\}$

Al no ser un problema  
linealmente separable,  
debe utilizarse un  
perceptrón multicapa





## Ejercicios del perceptrón multicapa

Ejercicio 3.1: dada la función XOR calcular la salida

Se calculó la matriz de confusión: esperado vs resultado

		Resultado	
		1	-1
Esperado	1	22	0
	-1	1	24

Epochs	500000
Corridas	12
beta	1
Learning rate	0.01
Capas ocultas	{4, 3}

# Ejercicios del perceptrón multicapa

Ejercicio 3.2: dados píxeles que forman números, definir la paridad

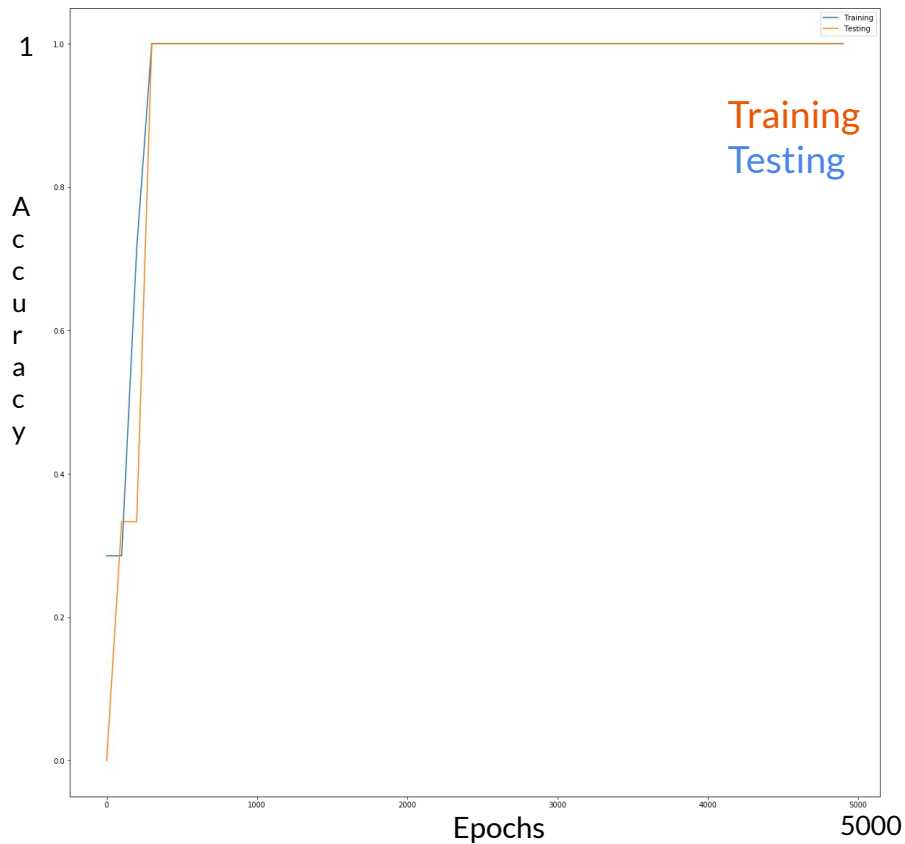
0 1 1 1 0	0 0 1 0 0	0 1 1 1 0	0 1 1 1 0	0 0 0 1 0	1 1 1 1 1	0 0 1 1 0	1 1 1 1 1	0 1 1 1 0	0 1 1 1 0
1 0 0 0 1	0 1 1 0 0	1 0 0 0 1	1 0 0 0 1	0 0 1 1 0	1 0 0 0 0	0 1 0 0 0	0 0 0 0 1	1 0 0 0 1	1 0 0 0 1
1 0 0 1 1	0 0 1 0 0	0 0 0 0 1	0 0 0 0 1	0 1 0 1 0	1 1 1 1 0	1 0 0 0 0	0 0 0 1 0	1 0 0 0 1	1 0 0 0 1
1 0 1 0 1	0 0 1 0 0	0 0 0 1 0	0 0 1 0 0	1 0 0 1 0	0 0 0 0 1	1 1 1 1 0	0 1 0 0 0	0 1 0 0 0	0 1 0 0 0
1 1 0 0 1	0 0 1 0 0	0 0 1 0 0	0 0 0 0 1	1 1 1 1 1	0 0 0 0 1	1 0 0 0 1	1 0 0 0 1	0 0 1 0 0	1 0 0 0 1
1 0 0 0 1	0 0 1 0 0	0 1 0 0 0	1 0 0 0 1	0 0 0 1 0	1 0 0 0 1	1 0 0 0 1	1 0 0 0 1	0 0 1 0 0	0 0 0 1 0
0 1 1 1 0	0 1 1 1 0	1 1 1 1 1	0 1 1 1 0	0 0 0 1 0	0 1 1 1 0	0 1 1 1 0	0 1 1 1 0	0 1 1 1 0	0 1 1 1 0

Entrenar con un subconjunto y testear con otro

# Gráfico de accuracy

Acc= bien clasificados/total

Epochs	100001
beta	1
Learning rate	0.01
Capas ocultas	{25, 20, 15, 10, 5}
Accuracy error	0.18






# Gráfico de accuracy

Acc= bien clasificados/total

Epochs	5000
beta	1
Learning rate	0.01
Capas ocultas	{25, 20, 15, 10, 5}
Accuracy error	0.1





## Ejercicios del perceptrón multicapa

Ejercicio 3.2: dados píxeles que forman números, definir la paridad

¿Qué podría decir acerca de la capacidad para generalizar de la red?

# Ejercicios del perceptrón multicapa

Ejercicio 3.3: dados píxeles que forman números, prender el bit de salida correspondiente

0	1	1	1	0
1	0	0	0	1
1	0	0	1	1
1	0	1	0	1
1	1	0	0	1
1	0	0	0	1
0	1	1	1	0

1000000000

0	0	1	0	0
0	1	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	1	1	1	0

0	1	1	1	0
1	0	0	0	1
0	0	0	0	1
0	0	0	1	0
0	0	1	0	0
0	1	0	0	0
1	1	1	1	1

0	1	1	1	0
1	0	0	0	1
0	0	0	0	1
0	0	1	1	0
0	0	0	0	1
1	0	0	0	1
0	1	1	1	0

0	0	0	1	0
0	0	1	1	0
0	1	0	1	0
1	0	0	1	0
1	1	1	1	1
0	0	0	1	0
0	0	0	1	0

0000010000

1	1	1	1	1
1	0	0	0	0
1	1	1	1	0
0	0	0	0	1
0	0	0	0	1
1	0	0	0	1
0	1	1	1	0

0	0	1	1	0
0	1	0	0	0
1	0	0	0	0
1	1	1	1	0
1	0	0	0	1
1	0	0	0	1
0	1	1	1	0

1	1	1	1	1
0	0	0	0	1
0	0	0	1	0
0	1	0	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0

0	1	1	1	0
1	0	0	0	1
1	0	0	0	1
0	1	1	1	0
1	0	0	0	1
1	0	0	0	1
0	1	1	1	0

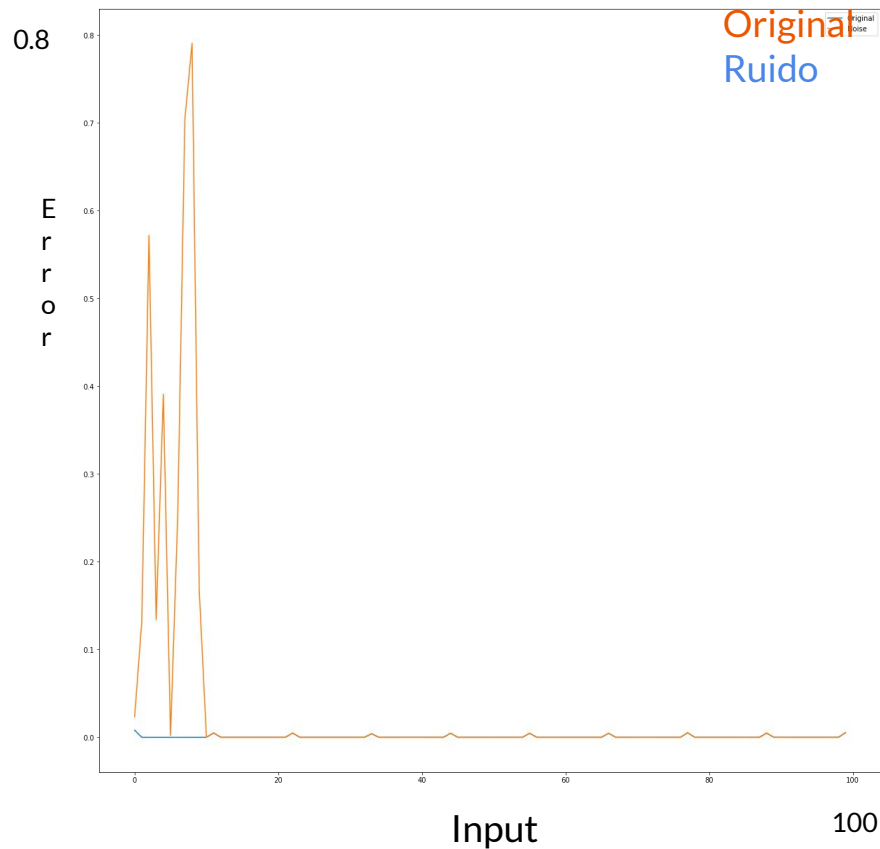
0	1	1	1	0
1	0	0	0	1
1	0	0	0	1
0	1	1	1	1
0	0	0	0	1
0	0	0	1	0
0	1	1	1	0

0000000001

Una vez que la red aprendió, aplicar ruido


# Error del ruido

Epochs	100001
beta	1
Learning rate	0.01
Capas ocultas	{25, 20, 15, 10, 5}
Probabilidad ruido	0.02



# Error del ruido

Epochs	100001
beta	1
Learning rate	0.01
Capas ocultas	{25, 20, 15, 10, 5}
Probabilidad ruido	0.5





# Muchas gracias

Grupo 19

Integrantes:

- Lucas Catolino
- Matias Ricarte